

Robustesse inter-annotateurs et primauté structurelle des gradients dans une classification organisationnelle fondée sur les gradients

Marie Maassouli

Avril 2026

Abstract

Une classification de systèmes complexes hétérogènes fondée sur les gradients a été proposée dans un article compagnon, dans lequel les frontières de régime organisationnel sont définies par des gradients inter-axes ($\Delta_{23} = A_2 - A_3$, $\Delta_{45} = A_4 - A_5$) plutôt que par des valeurs absolues d’axes. La présente étude teste si cette structure de gradients est robuste entre annotateurs indépendants. Vingt-neuf systèmes couvrant des domaines biologiques, technologiques, institutionnels, économiques et sociaux ont été évalués par trois annotateurs : un couple humain–LLM (A0), et deux LLM indépendants (Gemini, GPT-4), chacun travaillant à partir de sources textuelles dédiées. Les résultats montrent que le gradient normativité–révision Δ_{45} est préservé de manière robuste entre toutes les paires d’annotateurs (Spearman $\rho = 0.69$ – 0.88 , tous $p < 0.001$), tandis que le gradient propagation–intégration Δ_{23} est robuste entre A0 et Gemini ($\rho = 0.78$) mais sensible à la calibration de l’axe d’intégration lorsqu’il est évalué par GPT-4 ($\rho = 0.58$). Les matrices de distances inter-systèmes sont corrélées à $\rho = 0.63$ – 0.76 entre paires d’annotateurs, indiquant que la structure relationnelle de l’espace organisationnel est préservée même lorsque les scores absolus divergent. Un protocole de prompts renforcés corrige les erreurs de cadrage identifiées (scoring historique vs. opérationnel, normativité endogène vs. imposée) et réduit les divergences sévères (≥ 0.30) de 14.5\

1 Introduction

Un article compagnon [1] a proposé de classer des systèmes complexes hétérogènes à l’aide de cinq axes — profondeur hiérarchique (A_1), capacité de propagation (A_2), intégration (A_3), normativité (A_4) et capacité de révision (A_5) — et a montré que les gradients entre axes, en particulier $\Delta_{23} = A_2 - A_3$ et $\Delta_{45} = A_4 - A_5$, sont de meilleurs discriminants du régime organisationnel que les valeurs absolues des axes. Un second article [2] a étendu cette analyse à 28 systèmes couvrant six domaines et a mis en évidence une faible dimensionnalité effective (ratio de participation ACP = 3.05), des rangs de gradients stables sous perturbation du scoring, et quatre familles morphodynamiques émergentes.

Cependant, tous les résultats antérieurs reposaient sur une seule configuration d’annotateur. Cela soulève une question immédiate : la structure identifiée dans [2] est-elle une propriété des systèmes, ou une propriété du scoreur ?

Le présent article aborde cette question directement. Sa thèse centrale est :

Ce que l’index morphodynamique capture n’est pas un ensemble de positions absolues, mais un patron d’ordres relationnels entre systèmes — proximités, séparations et rangs de gradients — partiellement invariant sous changement d’annotateur. Les gradients fonctionnent comme des invariants relationnels sous perturbation du scoring, non comme des coordonnées intrinsèques au sens absolu.

C’est une affirmation plus faible que « les gradients mesurent des propriétés réelles des systèmes » et plus forte que « les gradients sont des artefacts du protocole ». Elle affirme que l’instrument produit une géométrie relationnelle structurellement cohérente, sans prétendre que cette géométrie soit fondamentale. La distinction importe : un invariant relationnel peut être utile comme système de coordonnées même si les axes sous-jacents sont imparfaitement calibrés, pourvu que les relations entre mesures soient préservées.

Pour tester cette thèse, nous avons évalué 29 systèmes avec trois configurations d’annotateurs indépendantes et examiné quatre hypothèses :

- **H1 (Convergence)** : Différence absolue moyenne inter-annotateurs ≤ 0.15 sur tous les axes.
- **H2 (Robustesse des gradients)** : Spearman $\rho > 0.70$ pour les rangs des gradients (Δ_{23} , Δ_{45}) entre paires d’annotateurs.
- **H3 (Contrainte A3–A4)** : La corrélation entre intégration et normativité persiste entre annotateurs.
- **H4 (Primauté des gradients)** : La variance inter-annotateurs sur les gradients est inférieure à celle sur les axes individuels.

2 Méthode

2.1 Systèmes

Vingt-neuf systèmes ont été évalués, couvrant six domaines : biologique (7 systèmes : cellule eucaryote, colonie de fourmis, microbiome intestinal, récif corallien, forêt tempérée, réseau neuronal biologique, psyché humaine), technologique (6 : noyau Linux, LLM statique, Internet BGP, réseau électrique, base de données PostgreSQL, thermostat domestique), institutionnel (7 : BCE, ordre bénédictin, Constitution américaine, bureaucratie, archive institutionnelle, armée prussienne, parlement en crise), économique (4 : chaîne d’approvisionnement mondiale, marché local, blockchain Bitcoin, pipeline industriel), social (3 : Wikipédia, Occupy Wall Street, collectif d’artistes), et scientifique (2 : cristal NaCl, startup en pivot).

2.2 Annotateurs

Trois configurations d’annotateurs ont été utilisées :

1. **A0 (référence)** : Scoreur humain assisté par Claude (Anthropic), évaluant dans des fils de conversation dédiés. Chaque système a été évalué indépendamment à partir de 3 sources textuelles par système. C’est la configuration de référence de [2].

2. **Gemini** : Google Gemini, évaluant à partir des mêmes sources textuelles ou de sources équivalentes (fournies en .epub, .pdf ou .txt). Deux passes ont été effectuées : une première passe (v1) avec un prompt standard, et une seconde passe (v2) avec des prompts renforcés pour 12 systèmes identifiés comme divergents.
3. **GPT-4** : OpenAI GPT-4, évaluant à partir de sources textuelles fournies en .txt. Prompt standard uniquement (pas de passe renforcée).

Tous les annotateurs ont utilisé le même protocole à 25 sous-critères (5 par axe, scorés 0/0.5/1). Aucun annotateur n'avait accès aux scores des autres.

2.3 Protocole de prompts renforcés

La première passe Gemini a révélé trois types d'erreurs systématiques :

1. **Confusion historique/opérationnel (A5)** : L'annotateur évalue la capacité de révision sur toute l'histoire du système plutôt qu'en fonctionnement actif. Affectés : armée prussienne (A5 : 1.00 $\rightarrow$ 0.40), Constitution (A5 : 1.00 $\rightarrow$ 0.60), archive (A5 : 1.00 $\rightarrow$ 0.30).
2. **Confusion endogène/imposé (A4)** : L'annotateur attribue la normativité à des contraintes de conception plutôt qu'à des normes produites par le système. Affecté : PostgreSQL (A4 : 0.90 $\rightarrow$ 0.70).
3. **Confusion structure/fonctionnement (A3, A4)** : L'annotateur évalue les institutions formelles plutôt que leur fonctionnement effectif au moment évalué. Affecté : parlement en crise (A3 : 1.00 $\rightarrow$ 0.20, A4 : 1.00 $\rightarrow$ 0.10).

Pour chaque type d'erreur, un bloc CRITICAL INSTRUCTIONS a été ajouté au prompt de scoring, spécifiant la distinction à appliquer et fournissant des exemples concrets. Le protocole complet des prompts est disponible dans le dépôt.

2.4 Analyse statistique

L'accord inter-annotateurs a été évalué par la différence absolue moyenne, la proportion de divergences sévères (≥ 0.30), et la corrélation de rang de Spearman sur les scores d'axes et les valeurs de gradients. La préservation structurelle a été évaluée en corrélant les matrices de distances par paires (distance euclidienne sur les axes standardisés) entre annotateurs. La contrainte A3–A4 a été testée par corrélation de Spearman au sein des scores de chaque annotateur.

3 Résultats

3.1 Accord au niveau des axes (H1)

H1 est validée pour A0–Gemini ($|\Delta|$ moyen = 0.105 < 0.15) et pour A0–GPT-4 (0.112), mais marginale pour Gemini–GPT-4 (0.126). Tous les annotateurs présentent un patron de biais systématique : A0 score en dessous de la moyenne sur tous les axes (biais moyen -0.05), GPT-4 score au-dessus (biais moyen $+0.03$), et Gemini v2 est approximativement neutre.

Table 1: Accord inter-annotateurs sur les scores d’axes (25 systèmes avec données complètes pour les 3 annotateurs).

Paire	\$	{ Δ }	\$ moyen	Médiane	Divergences ≥ 0.30
A0–Gemini v2	0.105	0.10	5.6\A0–GPT-4	0.112	0.10
11.2\Gemini–GPT-4	0.126	0.10	14.4\		

Le biais n’est pas uniforme entre les axes. Le biais positif de GPT-4 est le plus fort sur A_3 (intégration, +0.03) et A_5 (révision, +0.04), qui sont précisément les axes définissant les deux gradients principaux. Ce biais axe-dépendant a des conséquences sur la robustesse des gradients (voir ci-dessous).

3.2 Effet des prompts renforcés

Table 2: Effet des prompts renforcés sur le scoring Gemini (12 systèmes re-scorés).

Métrique	Gemini v1	Gemini v2
\$	{ Δ }	\$ moyen vs A0
0.130	0.114	
Divergences ≥ 0.30	14.5\\$	{ Δ }
\$ max	0.80	0.70
$\rho(\Delta_{23})$ vs A0	0.565	0.757
$\rho(\Delta_{45})$ vs A0	0.338	0.780

Les prompts renforcés réduisent les divergences sévères de 52\

Les divergences résiduelles après renforcement des prompts sont interprétatives plutôt que procédurales : elles reflètent des désaccords véritables sur les seuils de sous-critères (par exemple, si l’apoptose compte comme un échec de résistance ou comme un mécanisme régulateur pour N5 dans la cellule eucaryote).

3.3 Robustesse des gradients (H2)

Table 3: Corrélations de rang de Spearman sur les valeurs de gradients (25 systèmes complets).

Gradient	A0–Gemini	A0–GPT-4	Gemini–GPT-4	Seuil H2
Δ_{45}	0.881	0.741	0.685	0.70
Δ_{23}	0.784	0.582	0.495	0.70

Δ_{45} passe H2 pour A0–Gemini et A0–GPT-4. Δ_{23} passe H2 uniquement pour A0–Gemini. Le gradient normativité–révision est la coordonnée inter-annotateurs la plus robuste de l’instrument.

La fragilité de Δ_{23} avec GPT-4 est traçable à l’inflation par GPT-4 de A_3 (intégration) sur les systèmes où l’intégration est partielle ou contestée : chaîne d’approvisionnement mondiale (A_3 : 0.40 vs 1.00), Occupy Wall Street (A_3 : 0.40 vs 0.80), startup (A_3 : 0.50 vs 0.70). GPT-4 tend à scorer la capacité d’intégration théorique plutôt que l’intégration effective, un problème de calibration qui pourrait être résolu en fournissant des exemples d’ancrage dans le prompt.

3.4 Contrainte A3–A4 (H3)

Table 4: Corrélation de Spearman entre A_3 et A_4 au sein de chaque annotateur.

Annotateur	$\rho(A_3, A_4)$	p
A0	0.712	0.0001
Gemini v2	0.628	0.0008
GPT-4	0.422	0.035

La corrélation persiste chez les trois annotateurs (tous $p < 0.05$). Elle est la plus forte pour A0, plus faible pour GPT-4, mais toujours positive et significative. H3 est validée : le couplage A3–A4 n’est pas un artefact du style de scoring d’un seul annotateur.

L’affaiblissement de la corrélation de A0 à GPT-4 est cohérent avec l’inflation de A_3 par GPT-4 : en scorant l’intégration plus haut sur les systèmes à faible intégration, GPT-4 comprime la plage de A_3 et réduit la corrélation apparente avec A_4 .

3.5 Primauté des gradients (H4)

Variance inter-annotateurs moyenne sur les gradients (Δ_{23}, Δ_{45}) : 0.0147. Variance inter-annotateurs moyenne sur les axes (A_1 – A_5) : 0.0102. Ratio : 1.44.

H4 est rejetée. Les gradients sont 44\

L’échec de H4 s’explique par la structure de biais non uniforme : les biais des annotateurs sont axe-dépendants (GPT-4 gonfle A_3 et A_5 plus que A_1 et A_4), de sorte que le biais ne s’annule pas dans la différence de gradient. Cela signifie que la primauté des gradients ne peut pas être démontrée par comparaison de variance seule. En revanche, elle peut être démontrée par corrélation de rang : Δ_{45} a une corrélation de rang inter-annotateurs plus élevée ($\rho = 0.88$) que tout axe individuel (corrélation la plus élevée pour un axe individuel : A_2 à $\rho = 0.85$). Les gradients portent une information structurellement plus préservée que les axes, même si leur variance absolue est plus élevée.

3.6 Préservation de la structure relationnelle

Table 5: Corrélation des matrices de distances par paires entre annotateurs.

Paire	ρ matrice de distances
A0–Gemini v2	0.757
A0–GPT-4	0.625
Gemini–GPT-4	0.525

Les matrices de distances inter-systèmes sont positivement corrélées pour toutes les paires. Cela signifie que si deux systèmes sont proches dans le scoring de A0, ils tendent à être proches dans celui de Gemini et de GPT-4 également. La structure de voisinage de l’espace organisationnel est robuste entre annotateurs, même lorsque les scores individuels d’axes divergent jusqu’à 0.30.

Ce résultat est la preuve la plus directe que l’espace organisationnel capture une structure relationnelle véritable : ce qui est préservé entre annotateurs n’est pas la position de chaque système,

mais le patron de proximités et de séparations entre systèmes.

4 Discussion

4.1 Structure relationnelle plutôt que valeurs absolues

Le résultat central de cette étude est que l’index morphodynamique produit une géométrie relationnelle partiellement préservée entre annotateurs indépendants. Les preuves sont triples : (a) les matrices de distances inter-systèmes sont corrélées à $\rho = 0.63$ – 0.76 , ce qui signifie que le patron de proximités et de séparations entre systèmes est robuste même lorsque les scores absolus divergent jusqu’à 0.30 ; (b) le gradient Δ_{45} préserve son ordonnancement de rang entre toutes les paires d’annotateurs ($\rho = 0.69$ – 0.88) ; et (c) la corrélation A_3 – A_4 persiste chez les trois annotateurs, suggérant une surface de contrainte structurelle dans l’espace.

Ce résultat est cohérent avec la thèse énoncée en introduction : ce que l’instrument capture n’est pas un ensemble de positions métriques, mais une structure relationnelle ordinale. Deux systèmes voisins pour un annotateur tendent à être voisins pour les autres. Un système rigide ($\Delta_{45} \gg 0$) pour un annotateur est rigide pour les autres. C’est précisément ce que signifie un invariant relationnel : l’ordonnancement est préservé sous perturbation du processus de mesure.

4.2 Statut des deux gradients principaux

Les deux gradients ont un statut empirique différent, et cette différence est elle-même informative.

Δ_{45} (normativité moins révision) se comporte comme un invariant relationnel robuste. Sa corrélation de rang dépasse 0.70 pour toutes les paires d’annotateurs impliquant A0. Il sépare les mêmes systèmes dans les mêmes groupes indépendamment de l’annotateur : les systèmes rigides (thermostat, armée prussienne, pipeline, bureaucratie) se regroupent à Δ_{45} élevé ; les systèmes fluides (startup, Occupy, collectif d’artistes) se regroupent à Δ_{45} faible ou négatif. La distinction entre « un système qui régule sans réviser » et « un système qui révisé plus qu’il ne régule » paraît stable entre différents agents de scoring.

Δ_{23} (propagation moins intégration) est robuste entre A0 et Gemini ($\rho = 0.78$) mais fragile avec GPT-4 ($\rho = 0.58$). Cette fragilité est traçable à un problème de calibration spécifique : GPT-4 gonfle A_3 (intégration) sur les systèmes où l’intégration est partielle ou contestée, scorant la capacité de coordination théorique plutôt que la coordination effective. C’est une sensibilité dépendante du protocole, pas nécessairement une propriété du gradient lui-même. Le protocole de prompts renforcés corrige partiellement ce problème pour Gemini (élevant $\rho(\Delta_{23})$ de 0.57 à 0.78), suggérant que Δ_{23} pourrait devenir plus robuste avec de meilleures ancrées de calibration pour A_3 .

L’évaluation honnête est donc : Δ_{45} est un invariant relationnel de l’instrument dans sa forme actuelle ; Δ_{23} est un invariant candidat dont la stabilité dépend de la calibration de l’axe d’intégration. Les travaux futurs devraient tester si la fourniture d’exemples d’ancrage explicites pour A_3 stabilise Δ_{23} entre types d’annotateurs.

4.3 Les erreurs comme signal

Les trois types d'erreurs identifiés (historique/opérationnel sur A_5 , endogène/imposé sur A_4 , structure/fonctionnement sur A_3/A_4) ne sont pas du bruit. Ils révèlent que la fiabilité de l'instrument dépend non seulement de la grille de scoring, mais du cadre cognitif que l'annotateur apporte au système. Un annotateur qui lit « capacité de révision » comme « ce que le système a révisé dans son histoire » scorera l'armée prussienne et la Constitution à $A_5 = 1.00$; un annotateur qui le lit comme « ce que le système peut réviser en fonctionnement actif » les scorera à $A_5 = 0.40$ – 0.60 . Le protocole de prompts renforcés corrige cela en rendant explicite le cadre intentionnel. Le fait que les corrections de cadrage réduisent les divergences sévères de plus de moitié (de 14.5\

4.4 Limites et le problème de l'annotateur

La limite la plus significative est la composition du pool d'annotateurs : les trois configurations impliquent des LLM, et deux d'entre elles (A0 et Gemini) ont été promptées avec des instructions comparables. Un lecteur sceptique pourrait arguer que la convergence observée reflète des biais statistiques partagés des modèles de langage plutôt que des propriétés structurelles véritables des systèmes. Nous ne pouvons pas exclure cela avec les données actuelles.

Cependant, trois observations atténuent cette préoccupation. Premièrement, le protocole de prompts renforcés montre que les annotations LLM sont sensibles aux instructions de cadrage de manière prévisible — le même LLM (Gemini) produit des scores nettement différents avant et après une correction de prompt d'un seul paragraphe. Ceci est incompatible avec un modèle qui reproduirait simplement un a priori statistique fixe. Deuxièmement, les divergences entre Gemini et GPT-4 sont substantielles (14.4\

Une résolution définitive nécessiterait des annotateurs humains pleinement indépendants — idéalement des experts de domaine évaluant des systèmes dans leur spécialisation. Cela reste un travail futur.

4.5 Implications pour l'instrument

Les résultats suggèrent trois modifications pour les protocoles de scoring futurs :

1. **Ancres de calibration.** Fournir 2–3 exemples scorés dans le prompt (par ex., « le thermostat a $A_3 \approx 0.80$; la chaîne d'approvisionnement a $A_3 \approx 0.40$ ») réduirait la divergence de calibration sur A_3 qui déstabilise Δ_{23} .
2. **CRITICAL INSTRUCTIONS obligatoires pour les systèmes ambigus.** Les trois types d'erreurs identifiés (historique/opérationnel, endogène/imposé, structure/fonctionnement) devraient être signalés systématiquement dans le protocole de scoring, pas uniquement a posteriori.
3. **H4 reformulée.** Au lieu de comparer les variances, tester si les corrélations de rang des gradients dépassent celles des axes individuels. Les données actuelles soutiennent cette reformulation pour Δ_{45} .

4.6 Conclusion

La classification organisationnelle fondée sur les gradients produit une géométrie relationnelle — un patron d’ordres, de proximités et de séparations entre systèmes — partiellement invariante sous changement d’annotateur. Le gradient normativité–révision Δ_{45} est un invariant relationnel robuste ; le gradient propagation–intégration Δ_{23} est un invariant candidat dont la stabilité dépend de la calibration de A_3 . La structure de voisinage de l’espace organisationnel, la surface de contrainte A_3 – A_4 , et les quatre familles morphodynamiques sont toutes préservées entre annotateurs.

Ces résultats établissent que l’instrument mesure quelque chose de structurellement cohérent : non pas que les gradients capturent des propriétés fondamentales des systèmes complexes, mais qu’ils produisent des coordonnées relationnelles stables sous perturbation du processus de mesure. C’est la condition minimale pour qu’un instrument soit utile comme système de coordonnées pour une enquête ultérieure.

Le classifieur, le protocole de scoring, le jeu de données complet (29 systèmes $\times$ 3 annotateurs), et toutes les notes de scoring avec justifications par sous-critère sont disponibles à <https://github.com/MM1i97/3-index-morphodynamique>.

5 Références

- [1] Maassouli, M. (2026). Toward a Gradient-Based Classification Space for Heterogeneous Complex Systems. *Preprint*. (Papier 1 : cadre et instrument.)
- [2] Maassouli, M. (2026). Empirical Geometry of Organizational Systems: A Gradient-Based Analysis of 28 Heterogeneous Complex Systems. *Preprint*. (Papier 2 : étude empirique.)